



Digital College

ENSINO DE HABILIDADES DIGITAIS

Formação Data Analytics

Professor: MSc. Daniel Teófilo

Aula 01



Quem sou?

Daniel Teófilo Vasconcelos

Data Analyst na Controladoria e Ouvidoria Geral do Estado do Ceará

Professor de Pós-Graduação na Unifor, FBUi, Uni7 e Unifametro

Coordenador e Professor de Data Analytics na Digital College

Mestrado em Sistemas de Apoio à Decisão na UECE

18 anos na área de Tecnologia da Informação

Análise de Dados: Fundamentos e Ferramentas





Ferramentas para Análise de Dados



Formatos de Arquivos

Trabalharemos com diversos formatos como .xls para planilhas, .txt para textos simples, .json e .xml para dados estruturados e .pdf para documentos formatados.



Bancos de Dados

Utilizaremos PostgreSQL como sistema gerenciador, junto com interfaces gráficas como PgAdmin e DBeaver para facilitar a interação com os dados.



Linguagens e IDEs

Python será nossa principal linguagem de programação, com ambiente Jupyter Notebook e Visual Studio Code para desenvolvimento e análise.



BI e ETL

Aprenderemos ferramentas essenciais como Power BI para visualização e Pentaho Data Integration para processos de extração, transformação e carga de dados.


O Ecossistema de Dados

Armazenamento

Bancos de dados relacionais e não-relacionais para persistência dos dados

Visualização

Dashboards e relatórios para comunicar resultados



Processamento

Transformação e limpeza de dados com ferramentas ETL

Análise

Técnicas estatísticas e algoritmos para extrair insights

O ecossistema de dados é composto por elementos interconectados que trabalham em conjunto para transformar dados brutos em informações úteis. Cada componente desempenha um papel fundamental no processo de análise de dados.

O Que é um Banco de Dados?

Definição Formal

Um banco de dados é uma coleção lógica e coerente de dados com significado implícito. Representa informações estruturadas que são organizadas para facilitar o acesso, a gestão e a atualização.

Representação do Mini-Mundo


Todo banco de dados é projetado para representar aspectos específicos do mundo real, chamados de mini-mundo. Essa representação permite simular e analisar fenômenos reais em um ambiente controlado.

Propriedades

Um banco de dados eficiente deve oferecer suporte a transações, controle de concorrência para acesso simultâneo, mecanismos de recuperação de falhas e protocolos de segurança robustos.

Os bancos de dados são a espinha dorsal de praticamente todos os sistemas computacionais modernos, permitindo o armazenamento estruturado de informações e seu acesso eficiente por diferentes aplicações.


Níveis de Abstração de Dados



A abstração de dados é um conceito fundamental em bancos de dados que permite separar a implementação física dos dados da forma como os usuários os visualizam. Essa separação em níveis facilita a manutenção e evolução dos sistemas.

No nível físico, preocupamo-nos com a organização dos bytes em disco. No nível conceitual, definimos entidades, atributos e relacionamentos. Já no nível de visões, adaptamos a apresentação dos dados para diferentes perfis de usuários.


Nível de Visões de Dados



O nível de visões representa a camada mais alta de abstração, onde os dados são apresentados de forma personalizada para diferentes perfis de usuários. Cada departamento ou função dentro de uma organização pode ter sua própria visão dos dados, mostrando apenas as informações relevantes para suas atividades.


As visões funcionam como "janelas virtuais" para os dados, permitindo controlar o acesso a informações sensíveis e simplificar a interação com o banco de dados. Isso contribui para a segurança e usabilidade do sistema como um todo.

Nível Conceitual de Dados



Modelo Entidade-Relacionamento

Representa as entidades do mundo real como retângulos, seus atributos como elipses, e os relacionamentos entre entidades como losangos. É uma forma visual de modelar a estrutura lógica dos dados.



Diagramas UML

Os diagramas de classe UML são utilizados para modelar estruturas de dados orientadas a objetos, definindo classes, atributos, métodos e como as classes se relacionam entre si.



Esquemas

Documentam a estrutura geral do banco de dados independente de implementação, mostrando todas as entidades, relacionamentos e restrições que compõem o modelo de dados.

O nível conceitual abstrai os detalhes de implementação física e foca na estrutura lógica dos dados. Este nível é vital para o design de banco de dados, pois estabelece uma visão completa e coerente do sistema antes de sua implementação.

Nível Físico de Dados



Estruturas de Armazenamento

Arquivos, índices e métodos de acesso utilizados para organizar os dados fisicamente nos dispositivos de armazenamento.



Otimização de Desempenho

Técnicas para melhorar a velocidade de acesso e processamento, incluindo particionamento, compressão e caching de dados.



Gerenciamento de Espaço

Estratégias para utilização eficiente do espaço em disco, considerando fragmentação e expansão dos dados ao longo do tempo.



Arquitetura Distribuída

Organização dos dados em múltiplos servidores para garantir disponibilidade, escalabilidade e tolerância a falhas.

O nível físico de dados representa a camada mais baixa de abstração, onde os dados são efetivamente armazenados em dispositivos físicos. Os administradores de banco de dados trabalham neste nível para garantir desempenho e confiabilidade.



Projeto de Banco de Dados: Visão Geral

Análise de Requisitos

Identificação das necessidades de dados da organização, entrevistas com stakeholders e documentação dos requisitos funcionais e não-funcionais que o banco de dados deve atender.

Modelagem Conceitual

Criação de modelos abstratos e independentes de tecnologia que representam as entidades, atributos e relacionamentos identificados durante a análise de requisitos.

Modelagem Lógica

Transformação do modelo conceitual em um modelo implementável para um tipo específico de SGBD, como o modelo relacional, definindo tabelas, chaves e relacionamentos.

Modelagem Física

Especificação detalhada para uma tecnologia específica de banco de dados, incluindo índices, particionamento, configurações de armazenamento e otimizações de desempenho.

O projeto de banco de dados é um processo metodológico que visa criar estruturas de dados eficientes e eficazes para suportar as necessidades de informação de uma organização. Seguindo estas etapas, conseguimos garantir que o banco de dados final atenda aos requisitos do negócio.

Projeto Conceitual de Banco de Dados



Compreensão do domínio

Entendimento profundo do negócio



Identificação de entidades

Objetos relevantes para o negócio



Definição de relacionamentos

Conexões entre as entidades




Validação do modelo

Revisão com stakeholders

O projeto conceitual é a primeira e uma das mais importantes fases do design de banco de dados. Nele, criamos uma representação de alto nível das informações que precisam ser armazenadas, independente de como serão implementadas tecnicamente.

Um bom modelo conceitual serve como base sólida para as fases seguintes e facilita a comunicação entre os especialistas técnicos e os usuários do negócio, reduzindo o risco de mal-entendidos e retrabalho.

Database Logical Design



Projeto Lógico de Banco de Dados

1

Modelo Conceitual

Diagrama Entidade-Relacionamento independente de tecnologia

↔

Mapeamento

Conversão para o modelo relacional

Table icon

Definição de Tabelas

Estruturas, chaves e restrições

✓✓

Normalização

Otimização da estrutura relacional

O projeto lógico transforma o modelo conceitual abstrato em uma representação que pode ser implementada em um Sistema Gerenciador de Banco de Dados. No caso de um SGBD relacional, isso significa definir tabelas, colunas, chaves primárias e estrangeiras.


Durante esta fase, aplicamos técnicas de normalização para minimizar redundâncias e anomalias de dados, garantindo a integridade e eficiência do banco de dados. O resultado é um esquema lógico que serve como blueprint para a implementação física.

Projeto Físico de Banco de Dados

Aspecto	Decisões de Design	Impacto no Sistema
Índices	Definição de índices primários e secundários	Velocidade de busca e atualização
Armazenamento	Particionamento, compressão, clusters	Eficiência de espaço e acesso
Configurações	Parâmetros de buffer, cache, logs	Desempenho geral e recuperação
Segurança	Controle de acesso, criptografia	Proteção e privacidade dos dados

O projeto físico é a etapa final do design de banco de dados, onde determinamos como o banco de dados será implementado em um SGBD específico. Nesta fase, consideramos aspectos técnicos como estruturas de armazenamento, métodos de acesso e configurações de sistema.

As decisões tomadas no projeto físico têm impacto direto no desempenho, escalabilidade e manutenção do banco de dados. Um bom projeto físico pode fazer a diferença entre um sistema ágil e responsivo e um sistema lento e problemático.



Modelo Relacional de Banco de Dados

Fundamentos do Modelo Relacional



Origens e Contexto

Proposto por Edgar F. Codd em 1970, representando um marco na história dos bancos de dados.



Base Matemática


Fundamentado na álgebra relacional, trazendo rigor matemático para o armazenamento de dados.



Aplicação Moderna

Base para a maioria dos SGBDs atuais como PostgreSQL, MySQL e Oracle.

O modelo relacional trouxe um paradigma estruturado e matematicamente fundamentado para a organização de dados, revolucionando a forma como as informações são armazenadas e acessadas em sistemas computacionais.



Relação = Tabela

Definição

Uma relação é uma tabela bidimensional composta por linhas e colunas, com um nome único no banco de dados.

Cada relação representa uma entidade ou um relacionamento do mundo real, como clientes, produtos ou pedidos.

As relações são o alicerce do modelo relacional, proporcionando uma estrutura lógica e organizada para representar entidades do mundo real dentro do ambiente de banco de dados.

Características

- Estrutura bidimensional
- Nome único no banco de dados
- Sem duplicação de tuplas (linhas)
- Ordem das tuplas não é relevante

Atributo = Coluna

Definição de Atributo

São as colunas de uma tabela que representam as propriedades ou características de uma entidade.

Componentes

- Nome único na relação
- Tipo de dado associado
- Restrições possíveis

Tipos de Dados


- VARCHAR (texto)
- INTEGER (números)
- DATE (datas)
- BOOLEAN (verdadeiro/falso)

No exemplo de uma tabela "Aluno", os atributos poderiam ser: id, nome, matrícula e curso. Cada um desses atributos define uma característica específica que desejamos registrar sobre a entidade Aluno.

Explore your data structure

Create new

Ulysses Brock



Available data types

Boolean

Date

Integer

String

Available data types

Date

Integer

String

String

Available data types

Date

Integer

String

String

Tupla = Linha

1

Conceito

Uma tupla representa uma linha em uma relação, contendo um valor para cada atributo definido.

2

Características


Cada tupla é uma instância única da entidade, com valores correspondentes a cada atributo da tabela.

3

Exemplo

Na tabela Livro: (1, 'Dom Quixote', 'Miguel de Cervantes', 1605, 'Romance')

As tuplas são a essência da informação no modelo relacional. Enquanto a estrutura da tabela define quais dados podem ser armazenados, as tuplas contêm os valores reais que representam entidades específicas no mundo real.



The screenshot shows a web application dashboard with a sidebar on the left containing navigation links like 'Dashboard', 'Data', and 'Settings'. The main content area displays a table titled 'Collopyt' with a search bar and a table icon. The table has three columns and multiple rows of data. The first column contains text, the second column contains text, and the third column contains text. The table is styled with a light blue header and alternating row colors.

Antigamente, Amigos Cuidam	Onde	TO
TI	Kein Cerebral	TO
II	Roth über Auszubildende	TO
III	Ein Interview	TO
IV	Acto Ococto Bodoen, Bente	TO
V	Begri Satzer	TO
VI	Bole Cdeola Bels	TO
VII	A Bile Cdeola Bels	TO
VIII	Sore Rele Alatin Dings	TO
IX	Dorge Collgard	TO
X	Eat Cote Doc Pfefer	TO
XI	Peic SSooke	TO
XII	Dire Bheoos Alorlent Odssetc	TO
XIII	MqstisEoccer	TO
XIV	Bile Sdeola Bels	TO
XV	Sojo Mfenc Cote	TO
XVI	Dato Cdeola Bels	TO
XVII	Rele Acote	TO
XVIII	Bole Bheoos Alorlent Odssetc	TO



Domínio = Conjunto de Valores



Definição

O domínio define o conjunto de valores válidos que um atributo pode assumir, estabelecendo limites e regras.



Importância

Garante a consistência e validade dos dados inseridos na tabela, prevenindo erros e inconsistências.




Exemplos

O domínio do atributo "ano_publicação" pode ser restrito a inteiros entre 1500 e 2023.

A definição clara de domínios é fundamental para manter a integridade dos dados. Ao especificar exatamente quais valores são aceitáveis para cada atributo, prevenimos a entrada de dados incorretos ou inconsistentes no sistema.

Chave Primária: Identificação Única




A chave primária é um conceito fundamental no modelo relacional, pois permite a identificação inequívoca de cada registro. Na tabela "Aluno", por exemplo, o atributo "id" seria uma chave primária típica, garantindo que cada estudante tenha um identificador único no sistema.

Chave Estrangeira: Integridade Referencial




Conceito

Atributo que referencia a chave primária de outra tabela



Função


Estabelece relações entre tabelas



Integridade Referencial

Previne valores órfãos ou inválidos

Na tabela "Emprestimo", o atributo "aluno_id" seria uma chave estrangeira que referencia o "id" da tabela "Aluno". Isso garante que todo empréstimo registrado esteja associado a um aluno válido existente no sistema, mantendo a integridade dos dados.



Unique.Ilcr

Timestamp

Chave Composta

Definição

Uma chave composta é formada por dois ou mais atributos que, em conjunto, identificam unicamente uma tupla na relação.

Aplicação

Utilizada quando um único atributo não é suficiente para garantir a unicidade de cada registro na tabela.

Exemplo Prático

Na tabela "Emprestimo_Livro", a combinação de "emprestimo_id" e "livro_id" pode formar uma chave primária composta, identificando unicamente cada item emprestado.

As chaves compostas são especialmente úteis em tabelas de relacionamentos muitos-para-muitos, onde a combinação de identificadores de duas entidades diferentes cria um registro único na tabela intermediária.


Chave Candidata

Definição

Conjuntos de atributos que poderiam servir como chave primária de uma relação.

Exemplo

Na tabela "Aluno", tanto "id" quanto "matrícula" poderiam ser chaves candidatas.



Características

Devem satisfazer as propriedades de unicidade e não nulidade, assim como a chave primária.

Seleção

Uma é escolhida como chave primária; as demais permanecem como chaves candidatas.

A identificação de chaves candidatas é um passo importante no design de banco de dados, pois permite escolher a mais adequada como chave primária, considerando fatores como desempenho e simplicidade.

Operações Relacionais



SELECT (Seleção)

Recupera dados que atendem a critérios específicos



INSERT (Inserção)

Adiciona novos registros à tabela



UPDATE

Modifica dados existentes na tabela



DELETE (Remoção)

Exclui registros que atendem a critérios específicos

Estas operações fundamentais, derivadas da álgebra relacional, permitem a manipulação completa dos dados armazenados. A linguagem SQL (Structured Query Language) implementa estas operações, tornando-se o padrão para interação com bancos de dados relacionais.

SGBDs Relacionais



MySQL

Sistema de código aberto amplamente utilizado em aplicações web. Conhecido por sua facilidade de uso e bom desempenho em operações de leitura.



PostgreSQL

SGBD open-source avançado com forte conformidade SQL e suporte a recursos sofisticados como tipos de dados personalizados e índices complexos.



Oracle

Solução robusta para ambientes corporativos. Oferece alta performance, disponibilidade e segurança, sendo amplamente adotado por grandes empresas.

A escolha do SGBD adequado depende de diversos fatores como requisitos de desempenho, orçamento, escala da aplicação e expertise técnica disponível. Cada sistema possui pontos fortes em cenários específicos.

Componente do Modelo Relacional

Relação = Tabela

TABELA DEPARTAMENTO		
ID	NOME	ID_REGIAO
10	VENDAS	1
20	OPERAÇÕES	1
30	ADMINISTRATIVO	2
40	FINANCEIRO	3

TABELA REGIÃO	
ID	NOME
1	NORTE
2	CENTRO
3	SUL

Componente do Modelo Relacional

Atributo = Coluna

TABELA DEPARTAMENTO		
ID	NOME	ID_REGIAO
10	VENDAS	1
20	OPERAÇÕES	1
30	ADMINISTRATIVO	2
40	FINANCEIRO	3


Atributos

Componente do Modelo Relacional

Valores dos Atributos = Domínio

TABELA DEPARTAMENTO		
ID	NOME	ID_REGIAO
10	VENDAS	1
20	OPERAÇÕES	1
30	ADMINISTRATIVO	2
40	FINANCEIRO	3

Domínio



Componente do Modelo Relacional

Conjunto de Atributo = Esquema

TABELA DEPARTAMENTO		
ID	NOME	ID_REGIAO
10	VENDAS	1
20	OPERAÇÕES	1
30	ADMINISTRATIVO	2
40	FINANCEIRO	3

← Esquema

Componente do Modelo Relacional

Tupla = Linha

TABELA DEPARTAMENTO		
ID	NOME	ID_REGIAO
10	VENDAS	1
20	OPERAÇÕES	1
30	ADMINISTRATIVO	2
40	FINANCEIRO	3

← Tupla

Componente do Modelo Relacional

Conjunto de Tuplas = Instância

TABELA DEPARTAMENTO		
ID	NOME	ID_REGIAO
10	VENDAS	1
20	OPERAÇÕES	1
30	ADMINISTRATIVO	2
40	FINANCEIRO	3


← Instância

Componente do Modelo Relacional

Campo = Encontro de Linha e Coluna

TABELA DEPARTAMENTO		
ID	NOME	ID_REGIAO
10	VENDAS	1
20	OPERAÇÕES	1
30	ADMINISTRATIVO	2
40	FINANCEIRO	3

Campo



Componente do Modelo Relacional

Conteúdo do Campo = Valor

TABELA DEPARTAMENTO		
ID	NOME	ID_REGIAO
10	VENDAS	1
20	OPERAÇÕES	1
30	ADMINISTRATIVO	2
40	FINANCEIRO	3

Valor

Campo

Componente do Modelo Relacional

Campos sem Conteúdo = Nulo

Dependentes				
Responsável	Id	Nome	Grau	CPF
101	1	Pedro Antunes	Filho	12547896521
101	2	Paula Antunes	Esposa	23654789541
102	1	Marcos Leitão	Marido	12457896231
103	1	Carlos Ventura	Filha	

Nulo – campo não possui valor

Componente do Modelo Relacional

Chave Primária


TABELA DEPARTAMENTO		
ID	NOME	ID_REGIAO
10	VENDAS	1
20	OPERAÇÕES	1
30	ADMINISTRATIVO	2
40	FINANCEIRO	3

TABELA REGIÃO	
ID	NOME
1	NORTE
2	CENTRO
3	SUL

Chave Primária (PK)

Componente do Modelo Relacional

Chave Primária = Atributo Único



Integridade de Chave Primária

Componente do Modelo Relacional

Chave Primária = Atributo Único


TABELA DEPARTAMENTO		
ID	NOME	ID_REGIAO
10	VENDAS	1
20	OPERAÇÕES	1
20	ADMINISTRATIVO	2
40	FINANCEIRO	3

PK

Integridade de Chave Primária

Componente do Modelo Relacional


Chave Primária = Atributo Obrigatório



Integridade de Entidade

Componente do Modelo Relacional


Chave Primaria = Atributo Obrigatório



Integridade de Entidade

Componente do Modelo Relacional

Chave Primária Simples



Componente do Modelo Relacional

Chave Primaria Composta

Dependentes				
Responsável	Id	Nome	Grau	CPF
101	1	Pedro Antunes	Filho	12547896521
101	2	Paula Antunes	Esposa	23654789541
102	1	Marcos Leitão	Marido	12457896231
103	1	Carlos Ventura	Filho	


Chave Primária Composta

Componente do Modelo Relacional

Chave Candidata

TABELA DEPARTAMENTO		
ID	NOME	ID_REGIAO
10	VENDAS	1
20	OPERAÇÕES	1
30	ADMINISTRATIVO	2
40	FINANCEIRO	3

Chaves Candidatas



Componente do Modelo Relacional

Chave Estrangeira

TABELA DEPARTAMENTO		
ID	NOME	ID_REGIAO
10	VENDAS	1
20	OPERAÇÕES	1
30	ADMINISTRATIVO	2
40	FINANCEIRO	3

Chave Estrangeira (FK)
em departamento para Região

TABELA REGIÃO	
ID	NOME
1	NORTE
2	CENTRO
3	SUL

Chave Primária (PK)
de Região

Componente do Modelo Relacional

Chave Estrangeira

TABELA DEPARTAMENTO		
ID	NOME	ID_REGIAO
10	VENDAS	1
20	OPERAÇÕES	1
30	ADMINISTRATIVO	2
40	FINANCEIRO	3

Chave Estrangeira (FK)
em departamento para Região

TABELA REGIÃO	
ID	NOME
1	NORTE
2	CENTRO
3	SUL

Chave Primária (PK)
de Região

Chave Estrangeira -> Integridade Referencial

Vamos Praticar?

1. Criar o seguinte banco de dados: biblioteca

```
CREATE DATABASE biblioteca;
```

2. Criar tabela livros

```
CREATE TABLE IF NOT EXISTS public.livros  
(  
    id serial NOT NULL,  
    titulo character varying(100),  
    autor character varying(100),  
    ano_publicacao integer,  
    genero character varying ,  
    CONSTRAINT livros_pkey PRIMARY KEY (id)  
)
```


Vamos Praticar?

3. Inserir valores na tabela livros

```
INSERT INTO public.livros (titulo, autor, ano_publicacao, genero)
VALUES ('Dom Quixote', 'Miguel de Cervantes', 1605, 'Romance');
```

```
INSERT INTO public.livros (titulo, autor, ano_publicacao, genero)
VALUES ('1984', 'George Orwell', 1949, 'Ficção Distópica');
```

```
INSERT INTO public.livros (titulo, autor, ano_publicacao, genero)
VALUES ('O Senhor dos Anéis', 'J.R.R. Tolkien', 1954, 'Fantasia');
```

```
INSERT INTO public.livros (titulo, autor, ano_publicacao, genero)
VALUES ('Crime e Castigo', 'Fiódor Dostoiévski', 1866, 'Romance');
```

```
INSERT INTO public.livros (titulo, autor, ano_publicacao, genero)
VALUES ('Orgulho e Preconceito', 'Jane Austen', 1813, 'Romance');
```


FIM

